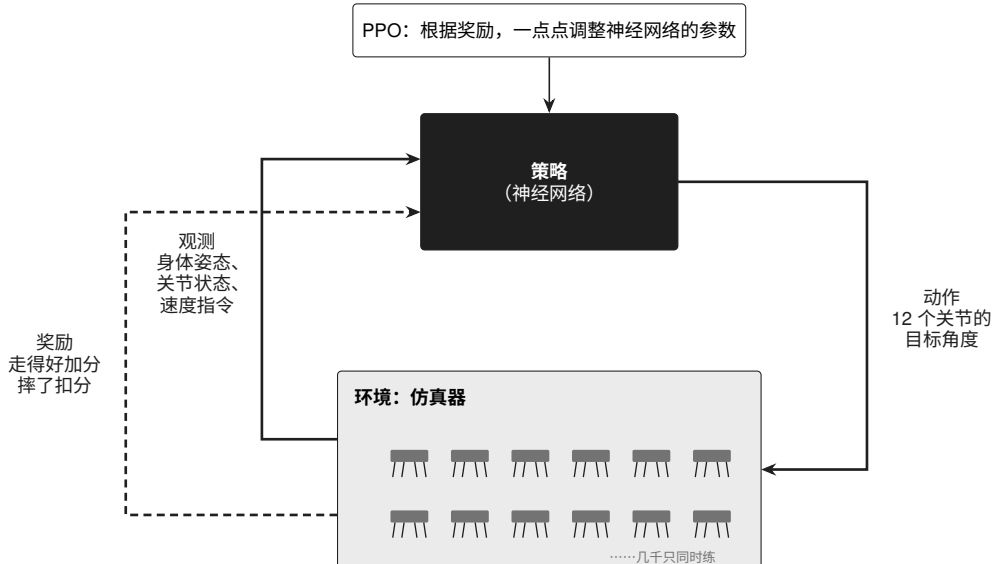
PPO：根据奖励，一点点调整神经网络的参数
策略
（神经网络）
观测
身体姿态、
关节状态、
速度指令
奖励
走得好加分
摔了扣分
动作
12 个关节的
目标角度
环境：仿真器
……几千只同时练